

Tóm tắt công thức

Mục lục

1	Đại số tuyến tính	3
1.1	Vector và Các Phép Toán Cơ Bản	3
1.1.1	Phép cộng và trừ Vector	3
1.1.2	Tích vô hướng (Dot Product)	3
1.2	Chuẩn (Norm) và Góc	3
1.2.1	Chuẩn Euclidean (L_2 -norm)	3
1.2.2	Chuẩn tổng quát (L_p -norm)	3
1.2.3	Bất đẳng thức Cauchy-Schwarz	3
1.2.4	Góc giữa hai vector	3
1.3	Ma trận và Phép nhân Ma trận	3
1.3.1	Nhân Ma trận - Vector (Ax)	3
1.3.2	Nhân Ma trận - Ma trận (AB)	3
1.3.3	Ma trận nghịch đảo	4
1.4	Các Không Gian Con Cơ Bản (The Four Fundamental Subspaces)	4
1.5	Các Phân Rã Ma Trận (Matrix Factorizations)	4
1.5.1	Phân rã $A = LU$ (Khử Gaussian)	4
1.5.2	Phân rã Hạng (Rank Factorization)	4
1.5.3	Phân rã $A = QR$ (Trực giao hóa)	4
1.6	Hình Chiếu (Projections) và Bình Phương Tối Thiểu	4
1.6.1	Ma trận chiếu lên một vector a	4
1.6.2	Hình chiếu lên không gian con (Least Squares)	4
1.7	Trực giao hóa Gram-Schmidt	5
2	Tóm tắt Công thức Lý thuyết Xác suất	5
2.1	Cơ sở về Xác suất	5
2.2	Biến ngẫu nhiên Rời rạc (Discrete Random Variables)	5
2.3	Các Phân phối Rời rạc Thông dụng	6
2.4	Biến ngẫu nhiên Liên tục (Continuous Random Variables)	6
2.5	Hiệp phương sai và Tương quan	6
2.6	Ước lượng Hợp lý Cực đại (MLE)	6
2.7	MLE cho Hồi quy Tuyến tính	6
3	Tóm tắt công thức: Phân tích Độ chệch và Phương sai	7
3.1	Độ đo sai số và Mục tiêu học tập	7
3.2	Phân rã MSE của một Ước lượng (Estimation)	7
3.3	Phân rã Độ chệch - Phương sai trong Học máy	7
3.4	Sự đánh đổi (Trade-off)	7
4	Tóm tắt các công thức quan trọng Linear Regression and Gradient Descent	8
4.1	Hồi quy tuyến tính (Linear Regression)	8
4.2	Hồi quy Logistic (Logistic Regression)	8
4.3	Thuật toán Gradient Descent	8
4.4	Xấp xỉ bậc hai (Quadratic Approximation)	8
5	Tóm tắt các công thức Hồi quy và Điều chuẩn	8
5.1	Hồi quy Tuyến tính Đơn giản (Simple Linear Regression)	8
5.2	Hồi quy Tuyến tính Đa biến (Multiple Linear Regression)	9

5.3	Hồi quy Đa thức (Polynomial Regression)	9
5.4	Điều chuẩn (Regularization)	9
5.4.1	Hồi quy Ridge (L_2 Regularization)	9
5.4.2	Hồi quy Lasso (L_1 Regularization)	9
6	Tóm tắt công thức Hồi quy Logistic	10
6.1	Mô hình (Model Representation)	10
6.2	Hàm mất mát (Loss Function)	10
6.3	Đạo hàm và Cập nhật tham số (Gradient Descent)	10
6.4	Biên quyết định (Decision Boundary)	10
7	Tóm tắt các công thức quan trọng: Hồi quy Softmax	11
7.1	Mô hình Softmax Regression	11
7.2	Hàm mất mát (Cross-Entropy Loss)	11
7.3	Gradient của Softmax + Cross Entropy	11
7.4	Gradient Descent	11
7.5	Dự đoán	11
8	Tóm tắt các công thức quan trọng: Mạng Nơ-ron Nhân tạo	12
8.1	Mô hình mạng nơ-ron nhiều lớp	12
8.2	Hàm kích hoạt Sigmoid	12
8.3	Hàm mất mát (Binary Cross-Entropy)	12
8.4	Lan truyền ngược (Backpropagation)	12
8.5	Gradient Descent	13
8.6	Dự đoán	13
9	Tổng hợp các công thức quan trọng trong Tối ưu hóa	13
9.1	Bài toán tối ưu	13
9.2	Cực trị địa phương	13
9.3	Đạo hàm và gradient	13
9.4	Đạo hàm theo hướng	13
9.5	Jacobian	13
9.6	Hessian	13
9.7	Dạng toàn phương và xác định	14
9.8	Điều kiện cực trị	14
9.9	Bài toán có ràng buộc	14
9.10	Tập và hàm lồi	14
9.11	Subgradient	14
9.12	Phương pháp bậc nhất	14
9.13	Line search	14
9.14	Exact line search (hàm bậc hai)	14
10	Tóm tắt các công thức quan trọng: Phương pháp Gradient	14
10.1	Điều kiện tối ưu bậc nhất	14
10.2	Hướng tăng / giảm nhanh nhất	15
10.3	Gradient Descent (GD)	15
10.4	Coordinate Descent	15
10.5	Điều kiện hướng giảm	15
10.6	Lựa chọn độ dài bước (Step size)	15
10.7	Hiện tượng zig-zag	15
10.8	Gradient Descent với Momentum	15
10.9	Trung bình lũy thừa (Exponential Moving Average)	15
10.10	Normalized Gradient Descent	15
10.11	RMSProp	15
10.12	Adam	16

1 Đại số tuyến tính

1.1 Vector và Các Phép Toán Cơ Bản

1.1.1 Phép cộng và trừ Vector

Cộng hoặc trừ từng thành phần tương ứng của hai vector cùng chiều:

$$x \pm y = \begin{bmatrix} x_1 \pm y_1 \\ \vdots \\ x_d \pm y_d \end{bmatrix} \quad (1)$$

1.1.2 Tích vô hướng (Dot Product)

Tổng của tích từng cặp phần tử tương ứng:

$$x \cdot y = \sum_{i=1}^d x_i y_i = y \cdot x \quad (2)$$

Tính chất phân phối: $x \cdot (y + z) = x \cdot y + x \cdot z$.

1.2 Chuẩn (Norm) và Góc

1.2.1 Chuẩn Euclidean (L_2 -norm)

Độ dài của vector:

$$\|x\|_2 = \sqrt{\sum_{i=1}^d x_i^2} = \sqrt{x \cdot x} \quad (3)$$

1.2.2 Chuẩn tổng quát (L_p -norm)

Với $p > 0$:

$$\|x\|_p = \left(\sum_{i=1}^d |x_i|^p \right)^{1/p} \quad (4)$$

1.2.3 Bất đẳng thức Cauchy-Schwarz

$$|x \cdot y| \leq \|x\| \cdot \|y\| \quad (5)$$

1.2.4 Góc giữa hai vector

Sử dụng định lý Cosine:

$$\cos(\theta) = \frac{x \cdot y}{\|x\| \cdot \|y\|} \quad (6)$$

Lưu ý: Hai vector được gọi là trực giao (vuông góc) khi tích vô hướng của chúng bằng 0.

1.3 Ma trận và Phép nhân Ma trận

1.3.1 Nhân Ma trận - Vector (Ax)

Phép nhân Ax có thể hiểu là tổ hợp tuyến tính của các cột trong A :

$$Ax = x_1 a_1 + x_2 a_2 + \cdots + x_n a_n \quad (7)$$

1.3.2 Nhân Ma trận - Ma trận (AB)

Phần tử c_{ij} của ma trận tích $C = AB$ là tích vô hướng của hàng i ma trận A và cột j ma trận B :

$$c_{ij} = (\text{row}_i \text{ of } A) \cdot (\text{column}_j \text{ of } B) \quad (8)$$

Hoặc có thể tính bằng tổng các ma trận hạng 1 (Rank-1 matrices):

$$AB = a_1 b_1^* + a_2 b_2^* + \cdots + a_n b_n^* \quad (9)$$

1.3.3 Ma trận nghịch đảo

Nếu ma trận vuông A khả nghịch, tồn tại A^{-1} sao cho:

$$A^{-1}A = I \quad \text{và} \quad AA^{-1} = I \quad (10)$$

Tính chất: $(AB)^{-1} = B^{-1}A^{-1}$.

1.4 Các Không Gian Con Cơ Bản (The Four Fundamental Subspaces)

Xét ma trận $A \in \mathbb{R}^{m \times n}$ có hạng r :

- **Column Space** $C(A)$: Không gian sinh bởi các cột của A , chiều = r .
- **Row Space** $C(A^T)$: Không gian sinh bởi các hàng của A , chiều = r .
- **Nullspace** $N(A)$: Tập nghiệm của phương trình $Ax = 0$, chiều = $n - r$.
- **Left Nullspace** $N(A^T)$: Tập nghiệm của phương trình $A^T y = 0$, chiều = $m - r$.

Tính chất trực giao (Orthogonality):

$$N(A) \perp C(A^T) \quad (11)$$

$$N(A^T) \perp C(A) \quad (12)$$

1.5 Các Phân Rã Ma Trận (Matrix Factorizations)

1.5.1 Phân rã $A = LU$ (Khử Gaussian)

Phân tích A thành ma trận tam giác dưới L và ma trận tam giác trên U :

$$A = LU \quad (13)$$

Trong đó hệ số nhân l_{ij} được tính bằng công thức: $l_{ij} = \frac{a_{ij}}{a_{jj}}$.

1.5.2 Phân rã Hạng (Rank Factorization)

$$A = CR \quad (14)$$

Với C chứa các cột độc lập tuyến tính của A , và R là ma trận bậc thang rút gọn dòng (row-reduced echelon form).

1.5.3 Phân rã $A = QR$ (Trực giao hóa)

$$A = QR \quad (15)$$

Với Q là ma trận trực giao (các cột trực chuẩn, $Q^T Q = I$) và R là ma trận tam giác trên.

1.6 Hình Chiếu (Projections) và Bình Phương Tối Thiểu

1.6.1 Ma trận chiếu lên một vector a

$$P = \frac{aa^T}{a^T a} \quad (16)$$

1.6.2 Hình chiếu lên không gian con (Least Squares)

Để giải bài toán xấp xỉ $Ax \approx b$ (khi $b \notin C(A)$), ta tìm $\hat{x}$ sao cho sai số $e = b - p$ vuông góc với không gian cột $C(A)$.

Phương trình pháp tuyến (Normal Equation):

$$A^T A \hat{x} = A^T b \quad (17)$$

Nghiệm tối ưu $\hat{x}$:

$$\hat{x} = (A^T A)^{-1} A^T b \quad (18)$$

Ma trận chiếu (Projection Matrix) P lên không gian cột của A :

$$P = A(A^T A)^{-1} A^T \quad (19)$$

Tính chất: $P^T = P$ và $P^2 = P$.

1.7 Trục giao hóa Gram-Schmidt

Biến đổi tập vector độc lập tuyến tính $\{a_1, \dots, a_k\}$ thành tập vector trực chuẩn $\{q_1, \dots, q_k\}$:

1. Bước 1 (Trục giao hóa):

$$\tilde{q}_1 = a_1 \quad (20)$$

$$\tilde{q}_i = a_i - \sum_{j=1}^{i-1} (q_j^T a_i) q_j \quad \text{với } i > 1 \quad (21)$$

2. Bước 2 (Chuẩn hóa):

$$q_i = \frac{\tilde{q}_i}{\|\tilde{q}_i\|} \quad (22)$$

2 Tóm tắt Công thức Lý thuyết Xác suất

2.1 Cơ sở về Xác suất

- **Định nghĩa Xác suất:** Với không gian mẫu rời rạc Ω , hàm xác suất P thỏa mãn:

$$P(\omega_k) \geq 0, \quad \sum_{k \in I} P(\omega_k) = 1 \quad (23)$$

- **Tính chất cơ bản:**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (24)$$

$$P(A^c) = 1 - P(A) \quad (25)$$

2.2 Biến ngẫu nhiên Rời rạc (Discrete Random Variables)

- **Hàm khối xác suất (PMF):**

$$p_X(x) = P(X = x), \quad p_X(x) \geq 0, \quad \sum_x p_X(x) = 1 \quad (26)$$

- **Kỳ vọng (Expectation):**

$$E[X] = \sum_x x p_X(x) \quad (27)$$

- **Định lý LOTUS:**

$$E[g(X)] = \sum_x g(x) p_X(x) \quad (28)$$

- **Tính tuyến tính của kỳ vọng:**

$$E[aX + b] = aE[X] + b \quad (29)$$

$$E[X + Y] = E[X] + E[Y] \quad (30)$$

- **Phương sai (Variance):**

$$Var(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2 \quad (31)$$

- **Tính chất phương sai:**

$$Var(aX + b) = a^2 Var(X) \quad (32)$$

$$Var(X + Y) = Var(X) + Var(Y), \quad \text{nếu } X, Y \text{ độc lập} \quad (33)$$

2.3 Các Phân phối Rời rạc Thông dụng

- Bernoulli(p):

$$P_X(x) = p^x(1-p)^{1-x} \quad (34)$$

$$E[X] = p, \quad Var(X) = p(1-p) \quad (35)$$

- Binomial(n, p):

$$P_X(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (36)$$

$$E[X] = np, \quad Var(X) = np(1-p) \quad (37)$$

- Geometric(p):

$$P_X(k) = (1-p)^{k-1} p \quad (38)$$

$$E[X] = \frac{1}{p}, \quad Var(X) = \frac{1-p}{p^2} \quad (39)$$

2.4 Biến ngẫu nhiên Liên tục (Continuous Random Variables)

- PDF:

$$P(a \leq X \leq b) = \int_a^b f(x) dx, \quad \int_{-\infty}^{\infty} f(x) dx = 1 \quad (40)$$

- Phân phối Chuẩn:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2} \quad (41)$$

$$E[X] = \mu, \quad Var(X) = \sigma^2 \quad (42)$$

- Gaussian đa biến:

$$N(y|\mu, \Sigma) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (y - \mu)^T \Sigma^{-1} (y - \mu) \right] \quad (43)$$

2.5 Hiệp phương sai và Tương quan

- Covariance:

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])] \quad (44)$$

$$= E[XY] - E[X]E[Y] \quad (45)$$

- Correlation:

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \quad (46)$$

2.6 Ước lượng Hợp lý Cực đại (MLE)

$$\hat{\theta}_{ML} = \arg \max_{\theta} L(x_1, \dots, x_n; \theta) \quad (47)$$

2.7 MLE cho Hồi quy Tuyến tính

$$p(y|\mathbf{x}; \mathbf{w}, \sigma^2) = \mathcal{N}(y|\mathbf{w}^T \mathbf{x}, \sigma^2) \quad (48)$$

$$RSS(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 \quad (49)$$

$$\mathbf{w}_{MLE} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (50)$$

3 Tóm tắt công thức: Phân tích Độ chệch và Phương sai

3.1 Độ đo sai số và Mục tiêu học tập

Trong bài toán học có giám sát, mục tiêu là tìm một mô hình giả thiết $h(\mathbf{x})$ xấp xỉ tốt hàm đích $f(\mathbf{x})$.

- Sai số tại một điểm dữ liệu (Squared Error):

$$err(\hat{y}, y) = (\hat{y} - y)^2 \quad (51)$$

- Sai số trong mẫu (In-sample error - E_{in}):

$$E_{in}(h) = \frac{1}{n} \sum_{i=1}^n err(h(\mathbf{x}_i), y_i) \quad (52)$$

- Sai số ngoài mẫu (Out-of-sample error - E_{out}):

$$E_{out}(h) = \mathbb{E}_{\mathbf{x}}[err(h(\mathbf{x}), f(\mathbf{x}))] \quad (53)$$

3.2 Phân rã MSE của một Ước lượng (Estimation)

Xét một tham số θ và ước lượng $\hat{\theta}$ của nó từ mẫu ngẫu nhiên. Sai số bình phương trung bình (MSE) được phân rã thành:

$$MSE(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + Bias^2(\hat{\theta}) \quad (54)$$

Trong đó:

- Độ chệch (Bias):

$$Bias(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta \quad (55)$$

- Phương sai (Variance):

$$Var(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2] \quad (56)$$

3.3 Phân rã Độ chệch - Phương sai trong Học máy

Xét bài toán hồi quy với dữ liệu có nhiễu:

$$y = f(\mathbf{x}) + \epsilon, \quad \mathbb{E}[\epsilon] = 0, \quad Var(\epsilon) = \sigma^2 \quad (57)$$

Gọi $h^{(\mathcal{D})}(\mathbf{x})$ là mô hình huấn luyện trên tập dữ liệu $\mathcal{D}$. Giả thiết trung bình (Average Hypothesis) tại điểm $\mathbf{x}_0$ là:

$$\bar{h}(\mathbf{x}_0) = \mathbb{E}_{\mathcal{D}}[h^{(\mathcal{D})}(\mathbf{x}_0)] \quad (58)$$

Kỳ vọng sai số trên một điểm dữ liệu mới $(\mathbf{x}_0, y_0)$ được phân rã:

$$\begin{aligned} \mathbb{E}_{\mathcal{D}}[(h^{(\mathcal{D})}(\mathbf{x}_0) - y_0)^2] &= \underbrace{\mathbb{E}_{\mathcal{D}}[(h^{(\mathcal{D})}(\mathbf{x}_0) - \bar{h}(\mathbf{x}_0))^2]}_{\text{Variance}} \\ &\quad + \underbrace{(\bar{h}(\mathbf{x}_0) - f(\mathbf{x}_0))^2}_{\text{Bias}^2} + \underbrace{\sigma^2}_{\text{Noise}} \end{aligned} \quad (59)$$

3.4 Sự đánh đổi (Trade-off)

- Mô hình đơn giản $\rightarrow$ High Bias, Low Variance.
- Mô hình phức tạp $\rightarrow$ Low Bias, High Variance.
- Mục tiêu tối ưu:

$$\min (Bias^2 + Variance) \quad (60)$$

4 Tóm tắt các công thức quan trọng Linear Regression and Gradient Descent

4.1 Hồi quy tuyến tính (Linear Regression)

Mô hình dự đoán giá trị thực y dựa trên biến đầu vào $\mathbf{x}$ và tham số trọng số $\mathbf{w}$:

$$y = f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b \quad (61)$$

Hàm mất mát sai số bình phương trung bình (Mean Squared Error - MSE) trên tập dữ liệu gồm N điểm, với $t^{(i)}$ là giá trị đích thực tế:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (t^{(i)} - f_{\mathbf{w}}(\mathbf{x}^{(i)}))^2 \quad (62)$$

4.2 Hồi quy Logistic (Logistic Regression)

Mô hình xác suất dự đoán nhãn lớp (sử dụng hàm sigmoid $\sigma(z) = \frac{1}{1+e^{-z}}$):

$$P(Y = 1|X = \mathbf{x}) = \sigma(\mathbf{w} \cdot \mathbf{x} + b) \quad (63)$$

Hàm mất mát cho Hồi quy Logistic (Log-likelihood âm):

$$\mathcal{L}(\mathbf{w}, b) = - \sum_n \log \sigma(y_n(\mathbf{w} \cdot \mathbf{x}_n + b)) \quad (64)$$

4.3 Thuật toán Gradient Descent

Quy tắc cập nhật tham số tại bước lặp $t + 1$ dựa trên giá trị tại bước t và hệ số học α (learning rate):

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \alpha \nabla L(\mathbf{w}_t) \quad (65)$$

Gradient của hàm mất mát MSE dưới dạng ma trận (Vectorization), trong đó $\mathbf{X}$ là ma trận thiết kế và $\mathbf{t}$ là vector giá trị đích:

$$\nabla_{\mathbf{w}} L = \frac{2}{N} \mathbf{X}^T (\mathbf{X} \mathbf{w} - \mathbf{t}) \quad (66)$$

4.4 Xấp xỉ bậc hai (Quadratic Approximation)

Gradient Descent có thể được xem là việc cực tiểu hóa một xấp xỉ bậc hai cục bộ của hàm số f tại điểm $\mathbf{x}$. Khai triển Taylor bậc hai (với số hạng bậc hai đơn giản hóa):

$$f(\mathbf{y}) \approx f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{1}{2\alpha} \|\mathbf{y} - \mathbf{x}\|^2 \quad (67)$$

Việc tìm cực tiểu của hàm xấp xỉ này theo $\mathbf{y}$ dẫn chính xác đến quy tắc cập nhật của Gradient Descent:

$$\mathbf{y}^* = \mathbf{x} - \alpha \nabla f(\mathbf{x}) \quad (68)$$

5 Tóm tắt các công thức Hồi quy và Điều chuẩn

5.1 Hồi quy Tuyến tính Đơn giản (Simple Linear Regression)

Mô hình dự đoán đầu ra y dựa trên đặc trưng đầu vào x :

$$f(x; w_0, w_1) = w_0 + w_1 x \quad (69)$$

Hàm mất mát (Loss function) - Tổng bình phương phần dư (RSS):

$$L(w_0, w_1) = \sum_{i=1}^N (y^{(i)} - (w_0 + w_1 x^{(i)}))^2 \quad (70)$$

Ước lượng bình phương tối thiểu (Least square estimates):

$$w_1 = \frac{\sum_{i=1}^N (y^{(i)} - \bar{y})(x^{(i)} - \bar{x})}{\sum_{i=1}^N (x^{(i)} - \bar{x})^2} \quad (71)$$

$$w_0 = \bar{y} - w_1 \bar{x} \quad (72)$$

Trong đó $\bar{y}$ và $\bar{x}$ là giá trị trung bình của dữ liệu.

5.2 Hồi quy Tuyến tính Đa biến (Multiple Linear Regression)

Mô hình tổng quát với vector đặc trưng $\mathbf{x}$ và vector trọng số $\mathbf{w}$:

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x} = w_0 + w_1 x_1 + \dots + w_D x_D \quad (73)$$

Hàm mất mát dạng ma trận (với $\mathbf{X}$ là ma trận thiết kế):

$$L(\mathbf{w}) = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w}) \quad (74)$$

Nghiệm phương trình pháp tuyến (Normal Equation) để tìm trọng số tối ưu:

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (75)$$

5.3 Hồi quy Đa thức (Polynomial Regression)

Mô hình sử dụng vector đặc trưng đa thức $\Phi(x)$ (biến đổi từ các đặc trưng ban đầu):

$$f(x; \mathbf{w}) = \mathbf{w}^T \Phi(x) \quad (76)$$

Lời giải tối ưu sử dụng ma trận đặc trưng Φ :

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y} \quad (77)$$

5.4 Điều chuẩn (Regularization)

Mục tiêu là cực tiểu hóa hàm mất mát kèm thành phần phạt để tránh quá khớp (overfitting):

$$\mathbf{w} = \arg \min_{\mathbf{w}} (L(\mathbf{w}) + \text{penalty}(\mathbf{w})) \quad (78)$$

5.4.1 Hồi quy Ridge (L_2 Regularization)

Hàm mất mát có thành phần phạt bình phương trọng số:

$$L_\lambda(\mathbf{w}) = \sum_{i=1}^N (y^{(i)} - f(\mathbf{x}^{(i)}; \mathbf{w}))^2 + \lambda \sum_{k=1}^D w_k^2 \quad (79)$$

Lời giải dạng đóng (Closed-form solution):

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y} \quad (80)$$

5.4.2 Hồi quy Lasso (L_1 Regularization)

Hàm mất mát có thành phần phạt trị tuyệt đối trọng số (giúp loại bỏ đặc trưng):

$$L_\lambda(\mathbf{w}) = \sum_{i=1}^N (y^{(i)} - f(\mathbf{x}^{(i)}; \mathbf{w}))^2 + \lambda \sum_{k=1}^D |w_k| \quad (81)$$

Lưu ý: Lasso không có lời giải dạng đóng do hàm giá trị tuyệt đối không khả vi tại 0.

6 Tóm tắt công thức Hồi quy Logistic

6.1 Mô hình (Model Representation)

Mô hình hồi quy logistic dự đoán xác suất đầu ra a (hoặc $\hat{y}$) dựa trên đặc trưng đầu vào $\mathbf{x}$ thông qua hàm kích hoạt sigmoid.

- **Hàm tuyến tính (Linear function / Score):**

$$z = \mathbf{w}^T \mathbf{x} + b = w_1 x_1 + w_2 x_2 + \dots + b \quad (82)$$

- **Hàm Sigmoid (Logistic function):**

$$a = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (83)$$

Trong đó $0 < a < 1$. Dự đoán nhãn $y = 1$ nếu $a \geq 0.5$ và $y = 0$ nếu $a < 0.5$.

6.2 Hàm mất mát (Loss Function)

Mục tiêu là tìm tham số $\mathbf{w}, b$ để cực đại hóa ước lượng hợp lý cực đại (Maximum Likelihood Estimation), tương đương với việc cực tiểu hóa hàm mất mát.

- **Hàm mất mát cho một điểm dữ liệu (Binary Cross-Entropy Loss):**

$$L(\mathbf{w}, b) = -(y \log(a) + (1 - y) \log(1 - a)) \quad (84)$$

- **Hàm chi phí cho toàn bộ tập dữ liệu (N điểm):**

$$J(\mathbf{w}, b) = - \sum_{i=1}^N \left[y^{(i)} \log(a^{(i)}) + (1 - y^{(i)}) \log(1 - a^{(i)}) \right] \quad (85)$$

6.3 Đạo hàm và Cập nhật tham số (Gradient Descent)

Áp dụng quy tắc dây chuyền (chain rule) để tính đạo hàm riêng phục vụ cho quá trình tối ưu hóa.

- **Đạo hàm của hàm Sigmoid:**

$$\frac{\partial a}{\partial z} = a(1 - a) \quad (86)$$

- **Gradient của hàm mất mát đối với trọng số w_j và bias b :**

$$\frac{\partial L}{\partial w_j} = (a - y)x_j \quad (87)$$

$$\frac{\partial L}{\partial b} = (a - y) \quad (88)$$

- **Gradient tổng quát (Vector hóa):**

$$\nabla L = (a - y)\mathbf{x} \quad (89)$$

6.4 Biên quyết định (Decision Boundary)

Biên quyết định là nơi xác suất dự đoán $a = 0.5$, tương ứng với $z = 0$. Trong không gian 2 chiều (x_1, x_2) , phương trình đường biên là:

$$w_1 x_1 + w_2 x_2 + b = 0 \implies x_2 = -\frac{w_1}{w_2} x_1 - \frac{b}{w_2} \quad (90)$$

7 Tóm tắt các công thức quan trọng: Hồi quy Softmax

7.1 Mô hình Softmax Regression

Với dữ liệu đầu vào $\mathbf{x} \in \mathbb{R}^d$, số lớp C :

$$\mathbf{z} = W\mathbf{x} + \mathbf{b}, \quad W \in \mathbb{R}^{C \times d}, \mathbf{b} \in \mathbb{R}^C \quad (91)$$

Hàm softmax:

$$a_k = \text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^C e^{z_j}}, \quad k = 1, \dots, C \quad (92)$$

7.2 Hàm mất mát (Cross-Entropy Loss)

Với nhãn one-hot $\mathbf{y} \in \mathbb{R}^C$:

$$\mathcal{L}(\mathbf{y}, \mathbf{a}) = - \sum_{k=1}^C y_k \log(a_k) \quad (93)$$

Với N mẫu:

$$J(W, \mathbf{b}) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(\mathbf{y}^{(i)}, \mathbf{a}^{(i)}) \quad (94)$$

7.3 Gradient của Softmax + Cross Entropy

Gradient theo $\mathbf{z}$:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{z}} = \mathbf{a} - \mathbf{y} \quad (95)$$

Gradient theo tham số:

$$\frac{\partial \mathcal{L}}{\partial W} = (\mathbf{a} - \mathbf{y})\mathbf{x}^T \quad (96)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}} = \mathbf{a} - \mathbf{y} \quad (97)$$

Gradient trung bình trên toàn bộ tập dữ liệu:

$$\nabla_W J = \frac{1}{N} \sum_{i=1}^N (\mathbf{a}^{(i)} - \mathbf{y}^{(i)})\mathbf{x}^{(i)T} \quad (98)$$

$$\nabla_{\mathbf{b}} J = \frac{1}{N} \sum_{i=1}^N (\mathbf{a}^{(i)} - \mathbf{y}^{(i)}) \quad (99)$$

7.4 Gradient Descent

Cập nhật tham số:

$$W \leftarrow W - \eta \nabla_W J \quad (100)$$

$$\mathbf{b} \leftarrow \mathbf{b} - \eta \nabla_{\mathbf{b}} J \quad (101)$$

trong đó η là learning rate.

7.5 Dự đoán

Nhân dự đoán:

$$\hat{y} = \arg \max_k a_k \quad (102)$$

8 Tóm tắt các công thức quan trọng: Mạng Nơ-ron Nhân tạo

8.1 Mô hình mạng nơ-ron nhiều lớp

Với mạng gồm L lớp, tại lớp l :

$$\mathbf{z}^{(l)} = W^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)} \quad (103)$$

$$\mathbf{a}^{(l)} = g^{(l)}(\mathbf{z}^{(l)}) \quad (104)$$

trong đó:

- $\mathbf{a}^{(0)} = \mathbf{x}$ (đầu vào),
- $W^{(l)}$ là ma trận trọng số,
- $\mathbf{b}^{(l)}$ là vector bias,
- $g^{(l)}(\cdot)$ là hàm kích hoạt.

8.2 Hàm kích hoạt Sigmoid

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (105)$$

Đạo hàm:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)) \quad (106)$$

8.3 Hàm mất mát (Binary Cross-Entropy)

Với nhãn $y \in \{0, 1\}$ và đầu ra a :

$$\mathcal{L}(y, a) = -[y \log(a) + (1 - y) \log(1 - a)] \quad (107)$$

8.4 Lan truyền ngược (Backpropagation)

Tại lớp đầu ra L :

$$\delta^{(L)} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{(L)}} = \mathbf{a}^{(L)} - \mathbf{y} \quad (108)$$

Gradient theo tham số:

$$\frac{\partial \mathcal{L}}{\partial W^{(L)}} = \delta^{(L)} \mathbf{a}^{(L-1)T} \quad (109)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{(L)}} = \delta^{(L)} \quad (110)$$

Lan truyền ngược về lớp l :

$$\delta^{(l)} = \left(W^{(l+1)T} \delta^{(l+1)} \right) \odot g'(\mathbf{z}^{(l)}) \quad (111)$$

Gradient tại lớp l :

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \delta^{(l)} \mathbf{a}^{(l-1)T} \quad (112)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{(l)}} = \delta^{(l)} \quad (113)$$

8.5 Gradient Descent

Với tập huấn luyện gồm N mẫu:

$$W^{(l)} \leftarrow W^{(l)} - \alpha \frac{1}{N} \sum_{i=1}^N \frac{\partial \mathcal{L}^{(i)}}{\partial W^{(l)}} \quad (114)$$

$$\mathbf{b}^{(l)} \leftarrow \mathbf{b}^{(l)} - \alpha \frac{1}{N} \sum_{i=1}^N \frac{\partial \mathcal{L}^{(i)}}{\partial \mathbf{b}^{(l)}} \quad (115)$$

trong đó α là learning rate.

8.6 Dự đoán

$$\hat{y} = \begin{cases} 1 & \text{nếu } a^{(L)} \geq 0.5 \\ 0 & \text{ngược lại} \end{cases} \quad (116)$$

9 Tổng hợp các công thức quan trọng trong Tối ưu hóa

9.1 Bài toán tối ưu

$$\theta^* = \arg \min_{\theta \in \Theta} L(\theta) \quad (117)$$

9.2 Cực trị địa phương

$$\exists \delta > 0, \forall \theta : \|\theta - \theta^*\| < \delta, \quad L(\theta^*) \leq L(\theta) \quad (118)$$

$$\exists \delta > 0, \forall \theta \neq \theta^* : \|\theta - \theta^*\| < \delta, \quad L(\theta^*) < L(\theta) \quad (119)$$

9.3 Đạo hàm và gradient

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \quad (120)$$

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} \quad (121)$$

9.4 Đạo hàm theo hướng

$$D_{\mathbf{v}} f(x) = \lim_{h \rightarrow 0} \frac{f(x + h\mathbf{v}) - f(x)}{h} = \nabla f(x)^\top \mathbf{v} \quad (122)$$

9.5 Jacobian

Với $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$:

$$J_f(x) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix} \quad (123)$$

9.6 Hessian

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix} \quad (124)$$

9.7 Dạng toàn phương và xác định

$$x^\top Ax \quad (125)$$

$$A \succeq 0 \iff x^\top Ax \geq 0, \forall x \quad (126)$$

$$A \succ 0 \iff x^\top Ax > 0, \forall x \neq 0 \quad (127)$$

9.8 Điều kiện cực trị

Cần:

$$\nabla L(\theta^*) = 0, \quad \nabla^2 L(\theta^*) \succeq 0 \quad (128)$$

Đủ:

$$\nabla L(\theta^*) = 0, \quad \nabla^2 L(\theta^*) \succ 0 \quad (129)$$

9.9 Bài toán có ràng buộc

$$\hat{\theta}^* = \arg \min_{\theta \in \mathcal{C}} L(\theta) \quad (130)$$

$$\mathcal{C} = \{\theta : g_j(\theta) \leq 0, h_k(\theta) = 0\} \quad (131)$$

9.10 Tập và hàm lồi

$$\lambda x + (1 - \lambda)y \in S, \quad \forall \lambda \in [0, 1] \quad (132)$$

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \quad (133)$$

$$f \text{ lồi} \iff \nabla^2 f(x) \succeq 0, \forall x \quad (134)$$

9.11 Subgradient

$$f(z) \geq f(x) + g^\top(z - x), \quad g \in \partial f(x) \quad (135)$$

9.12 Phương pháp bậc nhất

$$\theta_{t+1} = \theta_t + \rho_t d_t \quad (136)$$

$$d_t = -\nabla L(\theta_t) \quad (137)$$

9.13 Line search

$$\rho_t = \arg \min_{\rho > 0} L(\theta_t + \rho d_t) \quad (138)$$

9.14 Exact line search (hàm bậc hai)

$$\rho^* = -\frac{d^\top (A\theta + b)}{d^\top A d} \quad (139)$$

10 Tóm tắt các công thức quan trọng: Phương pháp Gradient

10.1 Điều kiện tối ưu bậc nhất

Với hàm khả vi $f : \mathbb{R}^n \rightarrow \mathbb{R}$,

$$\nabla f(x^*) = 0 \quad (140)$$

10.2 Hướng tăng / giảm nhanh nhất

$$\text{Hướng tăng nhanh nhất: } \nabla f(x) \quad (141)$$

$$\text{Hướng giảm nhanh nhất: } -\nabla f(x) \quad (142)$$

10.3 Gradient Descent (GD)

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (143)$$

10.4 Coordinate Descent

Cập nhật theo từng tọa độ:

$$x_i^{(k+1)} = x_i^{(k)} - \alpha_k \frac{\partial f(x^{(k)})}{\partial x_i} \quad (144)$$

10.5 Điều kiện hướng giảm

Hướng d là hướng giảm nếu:

$$\nabla f(x)^\top d < 0 \quad (145)$$

10.6 Lựa chọn độ dài bước (Step size)

$$\alpha_k > 0 \quad (146)$$

Line search:

$$\alpha_k = \arg \min_{\alpha > 0} f(x_k + \alpha d_k) \quad (147)$$

10.7 Hiện tượng zig-zag

Xảy ra khi các mức độ cong theo các hướng khác nhau quá chênh lệch:

$$\nabla f(x_k) \perp \text{đường đồng mức} \quad (148)$$

10.8 Gradient Descent với Momentum

$$v_k = \beta v_{k-1} + \nabla f(x_k) \quad (149)$$

$$x_{k+1} = x_k - \alpha v_k \quad (150)$$

10.9 Trung bình lũy thừa (Exponential Moving Average)

$$m_k = \beta m_{k-1} + (1 - \beta) g_k \quad (151)$$

10.10 Normalized Gradient Descent

Chuẩn hóa toàn bộ gradient:

$$x_{k+1} = x_k - \alpha \frac{\nabla f(x_k)}{\|\nabla f(x_k)\|} \quad (152)$$

Chuẩn hóa theo từng thành phần:

$$x_{k+1}^{(i)} = x_k^{(i)} - \alpha \frac{g_k^{(i)}}{|g_k^{(i)}|} \quad (153)$$

10.11 RMSProp

$$s_k = \beta s_{k-1} + (1 - \beta) g_k^2 \quad (154)$$

$$x_{k+1} = x_k - \alpha \frac{g_k}{\sqrt{s_k} + \varepsilon} \quad (155)$$

10.12 Adam

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k \quad (156)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2 \quad (157)$$

$$\hat{m}_k = \frac{m_k}{1 - \beta_1^k} \quad (158)$$

$$\hat{v}_k = \frac{v_k}{1 - \beta_2^k} \quad (159)$$

$$x_{k+1} = x_k - \alpha \frac{\hat{m}_k}{\sqrt{\hat{v}_k} + \varepsilon} \quad (160)$$